



SIMULACIONES Y PROCESOS ESTOCÁSTICOS

2026

Teoría: Dr. Alejandro Mezio – mezioalejandro@uca.edu.ar

Práctica: Dr. Luis Herrera – lherrera@uca.edu.ar



PROBABILIDAD Y VARIABLES ALEATORIAS

ESPACIO MUESTRAL

Dado un experimento, se llama **espacio muestral** al conjunto de resultados del experimento

Ejemplo:

En una carrera de 3 caballos, se considera el orden de llegada a la meta

$$S = \{ (1, 2, 3), (1, 3, 2), (2, 1, 3), (2, 3, 1), (3, 1, 2), (3, 2, 1) \}$$

Un **evento** es un subconjunto de S.

$$A = \{\text{resultados en los que el caballo 1 salga último}\}$$

$$A = \{ (2, 3, 1), (3, 2, 1) \}$$

EVENTOS

También son **eventos**:

1. Unión de eventos: $A \cup B$
2. Intersección de eventos: $A \cap B$
3. Complemento de evento: A^c

Y por lo tanto, también son eventos:

1. $A_1 \cup A_2 \cup A_3 \cup \dots \cup A_n$
2. $A_1 \cap A_2 \cap A_3 \cap \dots \cap A_n$
3. $S = A \cup A^c$
4. $A \cap A^c = \emptyset$

A y B son mutuamente excluyentes si $A \cap B = \emptyset$

AXIOMAS DE PROBABILIDAD

P es una **probabilidad** sobre el espacio muestral **S** si:

1. $0 \leq P(A) \leq 1$, para todo evento A
2. $P(S) = 1$
3. Para cualquier secuencia de eventos mutuamente excluyentes $A_1, A_2, \dots$

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) , \quad n = 1, 2, \dots, \infty$$

Por lo tanto:


$$1 = P(S) = P(A \cup A^c) = P(A) + P(A^c) \Rightarrow P(A^c) = 1 - P(A)$$

PROBABILIDAD CONDICIONAL (BAYES)

Probabilidad de que ocurra el evento A dado que ocurrió $B \rightarrow P(A|B)$

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{\text{Diagram 1}}{\text{Diagram 2}}$$

$$P(B|A) = \frac{P(B \cap A)}{P(A)} = \frac{\text{Diagram 3}}{\text{Diagram 4}}$$



Teorema de Bayes: $P(A|B) = \frac{P(B|A) P(A)}{P(B)}$

A y B independientes si:

$$P(A|B) = P(A)$$


$$\Rightarrow P(A \cap B) = P(A) P(B)$$

PROBABILIDAD CONDICIONAL (BAYES)

$$A = (A \cap B) \cup (A \cap B^c)$$

Entonces:

$$\begin{aligned} P(A) &= P(A \cap B) + P(A \cap B^c) \\ &= P(A|B) P(B) + P(A|B^c) P(B^c) \end{aligned}$$



$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

PROBABILIDAD CONDICIONAL (BAYES)

¿Cómo interpreto los resultados de un análisis?

¿Cómo le arrojo estadística a mis decisiones para que sean mejores?


¿Qué es evidencia? ¿y cuánto pesa esa evidencia?

<https://elgatoylacaja.com/notas/dime-que-no>

Calcula la probabilidad de ser HIV+ dado que un test nos dio positivo

- $A \rightarrow$ ser HIV+
- $B \rightarrow$ que el test de postivo
- Sensibilidad de 99% $\rightarrow$ de 100 positivos predice 99
- Evidencia previa: 0,4 % de la población es HIV+

$$P(A|B) = 0,28 \quad !!!$$



$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

VARIABLES ALEATORIAS

Variables aleatorias $\rightarrow X, Y, Z, \dots$

Valores que toman esas variables aleatorias $\rightarrow x, y, z, \dots$

Función de distribución acumulada:

$$F(x) = P(X \leq x)$$

$P(X \leq x)$ es la probabilidad asociada con el evento $\{X \leq x\}$, es decir, que la variable aleatoria X tome un valor no mayor a x .

Propiedades:

1. $0 \leq F(x) \leq 1$
2. $F(x)$ es no decreciente
3. $\lim_{x \rightarrow \infty} F(x) = 1$ y $\lim_{x \rightarrow -\infty} F(x) = 0$

VARIABLES ALEATORIAS DISCRETAS



X sólo puede tomar un número finito o numerable de valores $x_1, x_2, \dots$

Función de masa de probabilidad:

$$p(x_i) = P(X = x_i)$$

donde

$$\sum_{i=1}^{\infty} p(x_i) = 1$$




VARIABLES ALEATORIAS CONTINUAS

Si X es una variable aleatoria continua, existe una función no negativa:

Función densidad de probabilidad f :

$$P(X \in C) = \int_C f(x) dx$$

- $F(x) = \int_{-\infty}^x f(y) dy$
- $\frac{dF(x)}{dx} = f(x)$
- $P\left(a - \frac{\varepsilon}{2} \leq X \leq a + \frac{\varepsilon}{2}\right) = \int_{a - \frac{\varepsilon}{2}}^{a + \frac{\varepsilon}{2}} f(x) dx \cong f(a) \cdot \varepsilon$
- $P(X = a) = 0$



VALOR ESPERADO

- Si X es una variable aleatoria discreta:

$$E[X] = \sum_i x_i P(X = x_i) = \sum_i x_i p(x_i)$$

- Si X es una variable aleatoria continua:

$$E[X] = \int_{-\infty}^{\infty} x f(x) dx$$

- El valor esperado no necesariamente es un valor posible de X

PROPIEDADES DEL VALOR ESPERADO

Si $g: \mathbb{R} \rightarrow \mathbb{R}$ es una función real, entonces $g(X)$ es una variable aleatoria y:

- Discretas:

$$E[g(X)] = \sum_i g(x_i) p(x_i)$$

- Continuas:

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f(x) dx$$

- Linealidad:

$$E[aX + b] = a E[X] + b$$

- Si X e Y son variables aleatorias:

$$E[X + Y] = E[X] + E[Y]$$

VARIANZA

Es una medida de la variación de X en torno a $\mu = E[X]$:

$$Var(X) = E[(X - \mu)^2] = E[X^2] - \mu^2$$

- No es lineal:

$$Var(aX + b) = a^2 Var(X)$$

- La varianza de la suma no es (necesariamente) la suma de las varianzas
- Covarianza de X e Y :

$$cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

- $Var(X + Y) = Var(X) + Var(Y) + 2 cov(X, Y)$

VARIANZA Y DESVIACIÓN ESTÁNDAR

- Si X e Y son independientes:

$$\text{cov}(X, Y) = 0$$

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

- Desviación Estándar:

$$\sigma(X) = \sqrt{\text{Var}(X)}$$



- Corelación de X e Y :

$$\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma(X) \cdot \sigma(Y)}$$

DISTRIBUCIONES DISCRETAS

UNIFORME



- n valores igualmente probables
- Función de masa de probabilidad $P(X = i) = \frac{1}{n}$
- Valor esperado $E[X] = \frac{n+1}{2}$
- Varianza $Var(X) = \frac{n^2-1}{12}$



DISTRIBUCIONES DISCRETAS

BERNOULLI (*¡lanzar moneda!*)

- Experimento cuyo resultado sólo toma 2 valores
- Éxito es $X = 1$ y ocurre con probabilidad p
- Fracaso es $X = 0$ y probabilidad $1 - p$
- $P(X = 1) = p$ y $P(X = 0) = 1 - p$
- $P(X = x) = p^x(1 - p)^{1-x}$, con $x \in \{0,1\}$
- Valor esperado $E[X] = p$
- Varianza $Var(X) = p(1 - p)$





DISTRIBUCIONES DISCRETAS

(independientes)

BINOMIAL: cuenta el número k de éxitos en n ensayos de Bernoulli



- X toma valores enteros de 0 a n
- $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$
- Valor esperado $E[X] = n p$
- Varianza $Var(X) = n p(1 - p)$
- Bernoulli es una Binomial con $n = 1$



DISTRIBUCIONES DISCRETAS

POISSON: también representa muchos experimentos de Bernoulli, pero cuenta el número de eventos en un intervalo (tiempo o espacio)

- Número de eventos que ocurren en un intervalo fijo de tiempo o espacio, dada una tasa promedio constante de ocurrencia (λ).
- Útil para modelar la probabilidad de ocurrencia de sucesos con probabilidades muy pequeña (sucesos raros).
- Poisson puede aproximar a la Binomial cuando n es muy grande y p es pequeña



DISTRIBUCIONES DISCRETAS



POISSON: cuenta el número de eventos en un intervalo fijo

- X toma valores enteros de 0 a ∞
- Parámetro positivo tasa promedio λ

- $$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

- Valor esperado $E[X] = \lambda$



- Varianza $Var(X) = \lambda$



DISTRIBUCIONES DISCRETAS

GEOMÉTRICA: cuenta el número de experimentos de Bernoulli hasta que ocurre un éxito

- X toma valores enteros de 0 a ∞
- p probabilidad de éxito de cada exp de Bernoulli
- $P(X = n) = p (1 - p)^{n-1}$
- Valor esperado $E[X] = \frac{1}{p}$
- Varianza $Var(X) = \frac{1-p}{p^2}$



DISTRIBUCIONES CONTINUAS

$$P(X \in C) = \int_C f(x) dx$$

UNIFORME



- X uniformemente distribuida en el intervalo (a, b)

$$f(X = x) = \begin{cases} \frac{1}{b-a} & , \quad a < x < b \\ 0 & , \quad \text{resto} \end{cases}$$

$$F(x) = \begin{cases} 0 & , \quad x \leq a \\ \frac{x-a}{b-a} & , \quad a < x < b \\ 1 & , \quad x \geq b \end{cases}$$

$$E[X] = \frac{a+b}{2}$$

$$Var(X) = \frac{(b-a)^2}{12}$$



DISTRIBUCIONES CONTINUAS

$$P(X \in C) = \int_C f(x) dx$$

EXPONENCIAL: Describe el tiempo transcurrido entre eventos independientes que ocurren a una tasa promedio constante

- Modela el tiempo hasta que un evento específico ocurra (ej, arribo de clientes!)

- $f(X = x) = \lambda e^{-\lambda x}$



- $F(x) = \int_0^x \lambda e^{-\lambda y} dy = 1 - e^{-\lambda x}$

- $E[X] = \frac{1}{\lambda}$

- $Var(X) = \frac{1}{\lambda^2}$

- No tiene memoria

$P[X > a + b \mid X > a] = P[X > b], \quad \forall a, b \geq 0$
(probabilidad de que un evento ocurra en 10 minutos es independiente de cuánto tiempo ya pasó)



DISTRIBUCIONES CONTINUAS

$$P(X \in C) = \int_C f(x) dx$$

NORMAL (GAUSSIANA)

- Todos los fenómenos aleatorios que ocurran con una media μ y desviación estándar σ
- $X \sim N(\mu, \sigma)$

$$\bullet f(X = x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



$$\bullet F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(y-\mu)^2}{2\sigma^2}} dy$$

$$\bullet E[X] = \mu$$

$$\bullet Var(X) = \sigma^2$$

- Distrib Normal Estándar $Z \sim N(0,1)$


$$f_Z(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad \phi(x) = \int_{-\infty}^x f_Z(y) dy$$



DISTRIBUCIONES CONTINUAS

$$P(X \in C) = \int_C f(x) dx$$

NORMAL (GAUSSIANA)




- ▶ $P(|X - \mu| < \sigma) \simeq 68\%$
- ▶ $P(|X - \mu| < 2\sigma) \simeq 95\%$
- ▶ $P(|X - \mu| < 3\sigma) \simeq 99.7\%$

DISTRIBUCIONES CONTINUAS

$$P(X \in C) = \int_C f(x) dx$$

NORMAL (GAUSSIANA)

- Para $\alpha \in (0,1)$, z_α es el número real tal que $P(Z > z_\alpha) = \alpha$
- Recordemos Z es la variable normal estándar.
- Por supuesto, también es $P(Z \leq z_\alpha) = 1 - \alpha$






Veamos algunos valores comunes:

DISTRIBUCIONES CONTINUAS

$$P(X \in C) = \int_C f(x) dx$$

NORMAL (GAUSSIANA)



TEOREMA CENTRAL DEL LÍMITE

- Principio fundamental en estadística
- Supongamos una variable aleatoria X con una distribución dado (cualquiera!)
- Tomamos una muestra aleatoria de muchos elementos de X y calculamos su valor medio
- Tomamos otra muestra, calculamos otro valor medio. Repetimos muchas veces

La variable aleatoria “valor medio de una muestra tomada de la distribución X ”...
posee una distribución NORMAL

LEY DE LOS GRANDES NÚMEROS

- En el teorema central de límite, vimos que las “estadísticas” de una muestra aleatoria de X tienen una distribución Normal.
- La Ley de Grandes Números me dice que mientras tome muestras más grandes, los valores de esas “estadísticas” se acercan a los valores de la distribución original (la población!)

Mientras más repita un experimento aleatorio, la media de la muestra se acercará cada vez más a la media de la población



FIN