



SIMULACIONES Y PROCESOS ESTOCÁSTICOS

2026

Teoría: Dr. Alejandro Mezio – mezioalejandro@uca.edu.ar

Práctica: Dr. Luis Herrera – lherrera@uca.edu.ar

CADENAS DE MARKOV

- G. Ciaburro, Hand-os Simulations...: Capítulo 5
- S. M. Ross, Simulation: Capítulo 12
- https://github.com/helcsnewsxd/models-and-simulation-subject/blob/main/clases/teorico/09_cadenas_de_markov.pdf

Repaso:

- Procesos estocásticos

Definición: Colección de variables aleatorias “similares” ordenadas en el tiempo, (y que están todas definidas en un mismo espacio muestral).

$X_1, X_2, X_3, \dots \rightarrow$ proceso estocástico de tiempo discreto

$\{X(t), t \geq 0\} \rightarrow$ proceso estocástico de tiempo continuo

- PROBABILIDAD CONDICIONAL (BAYES)

Probabilidad de que ocurra el evento A dado que ocurrió $B \rightarrow P(A|B)$

Proceso de Markov

Definición: Proceso estocástico en el cual la probabilidad de que ocurra un evento depende solamente del evento previo.

Cadena de Markov

Definición: Si es un proceso de Markov de tiempo discreto, se lo conoce como Cadena de Markov

- Proceso estocástico de tiempo discreto: $X_1, X_2, X_3, \dots$
- Probabilidad de que ocurra un evento depende solamente del evento previo:

$$P(X_n = x_n | X_{n-1} = x_{n-1}, \dots, X_1 = x_1, X_0 = x_0) = P(X_n = x_n | X_{n-1} = x_{n-1})$$

Cadenas de Markov

Formalicemos un poco más:

- S es el conjunto de estados posibles del proceso de Markov, es el espacio muestral de valores posibles que puede tomar la variable X .
- Aclaración: En realidad una cadena de Markov es cuando el tiempo es discreto, pero también es discreto el espacio muestral S (no es continuo).
- Insistiendo en la aclaración: tengo la sucesión de variables aleatorias X_t , donde t indica el tiempo que es discreto, mientras que los posibles valores que puede tomar X_t son también discretos (son los elementos del espacio muestral S)
- Un proceso estocástico discreto es una cadena de Markov si

$$P(X_n = x_n | X_{n-1} = x_{n-1}, \dots, X_1 = x_1, X_0 = x_0) = P(X_n = x_n | X_{n-1} = x_{n-1})$$

para cada $x_0, x_1, x_2, \dots, x_n \in S$

Cadenas de Markov

Probabilidades de transición

Dada una cadena de Markov, que notamos $\{X_n\}_{n \geq 0}$, con un conjunto de estados $S = \{0, 1, 2, 3, \dots\}$, llamamos probabilidad de transición a:

$$p_{ij} = P(X_{n+1} = j | X_n = i) \quad i, j \in S$$

- En el paso o instante n me encuentro en el estado i , es decir $X_n = i$.
- La probabilidad de que en el próximo instante $(n + 1)$ me encuentre en el estado j , es p_{ij}
- p_{ij} es la probabilidad de transición desde el estado i al estado j
- Una cadena de Markov se dice **homogénea** si p_{ij} depende de los estados i, j pero no depende del instante n
 - $p_{ij} \geq 0$ para todo par $i, j \in S$
 - $\sum_j p_{ij} = 1$ para todo $i \in S$ (desde i el sistema transiciona a algún estado)

Cadenas de Markov

Distribución inicial de la cadena

La distribución de probabilidad para el estado inicial de la cadena es la función:

$$\pi(j) = P(X_0 = j) , \quad j \in S$$

- $\pi(j) \geq 0$ para todo $j \in S$
- $\sum_j \pi(j) = 1$

(También le llaman p_j^0)

De esta manera, teniendo las **probabilidades de transición** p_{ij} y la **distribución inicial** $\pi(j)$, la cadena de Markov queda unívocamente determinada.

Para una secuencia particular de $N + 1$ elementos $X_0, X_1, X_2, \dots, X_N$, la distribución conjunta es

$$P(X_0 = x_0, X_1 = x_1, X_2 = x_2, \dots, X_N = x_N) = \pi(x_0) \cdot p_{x_0 x_1} \cdot p_{x_1 x_2} \cdots p_{x_{N-1} x_N}$$

Cadenas de Markov

Matriz de transición

Supongamos que tenemos un número finito de estados, es decir $S = \{0, 1, 2, 3, \dots, N\}$ y la cadena de Markov es homogénea.

Se vuelve útil la adopción de la Matriz de transición:

$$Q = (p_{ij}) = \begin{pmatrix} p_{00} & p_{01} & p_{02} & \cdots & p_{0N} \\ p_{10} & p_{11} & p_{12} & \cdots & p_{1N} \\ p_{20} & p_{21} & p_{22} & \cdots & p_{2N} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ p_{N0} & p_{N1} & p_{N2} & \cdots & p_{NN} \end{pmatrix}$$

Tiene las (obvias) propiedades:

- Todos sus elementos son positivos, es más, $0 \leq p_{ij} \leq 1$
- La suma de cada fila es 1: $\sum_{j=0}^N p_{ij} = 1$ para cada i

La Matriz Q permite calcular la probabilidad de transición de un estado a otro en más de un paso

Cadenas de Markov

Matriz de transición

Supongamos que queremos calcular la probabilidad de en el 2do paso estar en el estado j cuando en el instante inicial estábamos en el estado i ,

$$\begin{aligned} P(X_2 = j | X_0 = i) &= \sum_{k=0}^N P(X_2 = j, X_1 = k | X_0 = i) \\ &= \sum_{k=0}^N P(X_2 = j | X_1 = k, X_0 = i) \cdot P(X_1 = k | X_0 = i) \\ &= \sum_{k=0}^N P(X_2 = j | X_1 = k) \cdot P(X_1 = k | X_0 = i) \\ &= \sum_{k=0}^N p_{jk} \cdot p_{ki} = (Q^2)_{ij} \end{aligned}$$

← Elemento ij de la matriz Q^2

Cadenas de Markov

Matriz de transición

Teorema: Sea Q la matriz de transición de una cadena de Markov. Entonces la matriz Q^n contiene las probabilidades de transición en n etapas.

Notación: Llamaremos $p_{ij}^{(n)}$ al elemento (i, j) de la matriz Q^n

Cadenas de Markov


Diagramas de transición

Es un grafo dirigido, donde los nodos son los estados de la cadena, y los arcos (o flechas) son las probabilidades de transición entre los estados que unen.

Contiene la misma información que la matriz de transición.

Ejemplo:

$$Q = \begin{matrix} & \begin{matrix} 1 & 2 & 3 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \end{matrix} & \begin{pmatrix} \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{2}{3} & 0 & \frac{1}{3} \\ \frac{1}{4} & \frac{1}{4} & \frac{2}{4} \end{pmatrix} \end{matrix}$$



Cadenas de Markov

$$Q = \begin{pmatrix} p_{00} & p_{01} & \cdots \\ p_{10} & p_{11} & \cdots \\ \cdots & \cdots & \cdots \end{pmatrix}$$

Practiquemos un poco:

Ejemplo 9.3. Supongamos que una máquina puede tener dos estados: en condiciones de operar (estado 0) y descompuesta (estado 1). Las probabilidades de transición están dadas por:

$$p_{01} = P(0, 1) = P(X_{n+1} = 1 \mid X_n = 0) = 0.15$$

$$p_{10} = P(1, 0) = P(X_{n+1} = 0 \mid X_n = 1) = 0.75.$$

$$Q = \begin{matrix} & \begin{matrix} 0 & 1 \end{matrix} \\ \begin{matrix} 0 \\ 1 \end{matrix} & \begin{pmatrix} 0.85 & 0.15 \\ 0.75 & 0.25 \end{pmatrix} \end{matrix}$$

- Si el estado inicial es **0**, la máquina tiene una probabilidad del 15 % de romperse y un 85 % de permanecer operativa.
- Si la máquina está rota tiene un 25 % de permanecer rota y un 75 % de ser reparada.

$$Q^2 = \begin{pmatrix} 0.835 & 0.165 \\ 0.825 & 0.175 \end{pmatrix}$$

$$Q^3 = \begin{pmatrix} 0.8335 & 0.1665 \\ 0.8325 & 0.1675 \end{pmatrix}$$

$$Q^4 = \begin{pmatrix} 0.83335 & 0.16665 \\ 0.83325 & 0.16675 \end{pmatrix}$$

“a la larga” vemos que la máquina tiene una tendencia a tener un 83,3% de probabilidad de estar operativa/reparada y un 16,6% de estar rota

Cadenas de Markov

$$Q = \begin{pmatrix} p_{00} & p_{01} & \cdots \\ p_{10} & p_{11} & \cdots \\ \cdots & \cdots & \cdots \end{pmatrix}$$


Practiquemos un poco:

Ejemplo 9.3. Supongamos que una máquina puede tener dos estados: en condiciones de operar (estado 0) y descompuesta (estado 1). Las probabilidades de transición están dadas por:

$$p_{01} = P(0, 1) = P(X_{n+1} = 1 \mid X_n = 0) = 0.15$$

$$p_{10} = P(1, 0) = P(X_{n+1} = 0 \mid X_n = 1) = 0.75.$$

$$Q = \begin{pmatrix} 0.85 & 0.15 \\ 0.75 & 0.25 \end{pmatrix}$$



Cadenas de Markov


$$Q = \begin{pmatrix} p_{00} & p_{01} & \cdots \\ p_{10} & p_{11} & \cdots \\ \cdots & \cdots & \cdots \end{pmatrix}$$

Practiquemos un poco:

Ejemplo 9.4. El país de Oz está bendecido por muchas bondades, pero no por el buen tiempo. Nunca hay dos días soleados seguidos. Cada día que hay sol, es igualmente probable que al día siguiente llueva o nieve. Si llueve o nieva, al día siguiente sigue igual o cambia el clima con igual probabilidad, y en caso que cambie el clima sólo la mitad de las veces sigue un día soleado.

	<i>L</i>	<i>N</i>	<i>S</i>
<i>L</i>	0.5	0.25	0.25
<i>N</i>	0.25	0.5	0.25
<i>S</i>	0.5	0.5	0

o específicamente $Q = \begin{pmatrix} 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \\ 0.5 & 0.5 & 0 \end{pmatrix}$



Cadenas de Markov

Notebooks con ejemplos (Ciaburro capítulo 5):

- Caminata aleatoria: `simulating_random_walk.py`
- Predicción del clima: `weather_forecasting.py`

Cadenas de Markov

Estructura de Clases

- Estado accesible: diremos que el estado j es **accesible** desde i , o que puede ser alcanzado desde i , si hay una probabilidad no nula de que la cadena de Markov iniciada en i llegue al estado j .

Es decir, existe algún n para el cual $p_{ij}^{(n)} = P(X_n = j \mid X_0 = i) > 0$

- Estados que se comunican: diremos que dos estados i y j se **comunican** entre sí si j es accesible desde i , y viceversa.

Esta relación divide al espacio de estados S en distintas **clases comunicantes**.

Cadenas de Markov

Estructura de Clases

- Subconjuntos cerrados: Sea C un subconjunto de S no vacío, diremos que C es **cerrado** $\Leftrightarrow \forall i \in C \wedge \forall j \notin C, j$ no es accesible desde i .
(si y sólo si para todo $i \in C$ y para todo $j \notin C, j$ no es accesible desde i)

Si la cadena de Markov alcanza un estado en C siempre permanecerá en C

- Subconjunto irreducible: Sea C un subconjunto cerrado, diremos que C es **irreducible** si y sólo si no contiene ningún subconjunto propio cerrado


Una cadena de Markov se dice irreducible si su espacio de estados S es irreducible

Cadenas de Markov

Estructura de Clases: Ejemplo

$$S = \{0, 1, 2, 3, 4, 5\}$$

Clases comunicantes: $\{0, 1, 2\}$, $\{3\}$, $\{4, 5\}$



Además $\{3, 4, 5\}$ es un subconjunto cerrado, pero no irreducible.

Esto sucede porque contiene a $\{4, 5\}$ que también es un subconjunto cerrado (y éste sí es irreducible)

**Pensar bien
por qué**

Cadenas de Markov

Clasificación de estados

- Llamaremos v_{ij} a la probabilidad de que la cadena que comienza en i llegue en una cantidad finita de pasos al estado j .

$$v_{ij} = P(X_n = j, \text{algún } n \geq 1 \mid X_0 = i)$$

(podemos ver que v_{ij} es el $p_{ij}^{(n)}$ de antes)

- Si existe un camino de i hasta j entonces $v_{ij} > 0$
- Si $v_{ij} = 1$ entonces cualquier camino que parte del estado i llega al estado j
- Si $v_{ij} < 1$ entonces existe al menos 1 camino que parte del estado i y desde el cual **no es posible** llegar al estado j


Cadenas de Markov

Clasificación de estados

El estado j es un estado:


- **Recurrente** si $v_{jj} = 1$
- **Transitorio** si no es recurrente

(es decir, si $v_{jj} \neq 1$)

- **Absorbente** si $p_{jj} = 1$ ➡ 

Notar que un estado recurrente es cuando **todos** los caminos que salen de él vuelven en un tiempo finito.

La recurrencia indica persistencia (regreso seguro), mientras que la transitoriedad indica temporalidad (posible abandono definitivo).



- 4 y 5 son recurrentes
- 0, 1, 2, 3 son transitorios
- Ninguno es absorbente

Cadenas de Markov

Una cadena de Markov se dice:

- **Recurrente** si todos sus estados son recurrentes
- **Transitoria** si todos sus estados son transitorios

- **Recurrente** si $v_{jj} = 1$
- **Transitorio** si $v_{jj} \neq 1$
- **Absorbente** si $p_{jj} = 1$

Si una cadena de Markov tiene un número finito de estados entonces **no puede ser transitoria**. Debe tener algún estado recurrente.

Supongamos i es un estado recurrente ($v_{ii} = 1$) y existe un camino de i a j , entonces j es recurrente y $v_{ij} = v_{ji} = 1$


Cadenas de Markov

Ejemplo:

$Q =$

	0	1	2	3	4	5
0	1	0	0	0	0	0
1	1/4	1/2	1/4	0	0	0
2	0	1/5	2/5	1/5	0	1/5
3	0	0	0	1/6	1/3	1/2
4	0	0	0	1/2	0	1/2
5	0	0	0	1/4	0	3/4

- **Recurrente** si $v_{jj} = 1$
- **Transitorio** si $v_{jj} \neq 1$
- **Absorbente** si $p_{jj} = 1$



Conjunto de estados
accesibles desde i

$$C_i = \{i\} \cup \{j \mid \nu_{ij} > 0\}$$

$$C_0 = \{0\}$$

$$C_1 = C_2 = \{0, 1, 2, 3, 4, 5\} = S$$

$$C_3 = C_4 = C_5 = \{3, 4, 5\}$$

Cada C_i es un conjunto cerrado

Además, C_0 y C_3 son irreducibles

Cadenas de Markov

Periodicidad de una cadena de Markov

- Sea i un estado recurrente, entonces existe un $n > 1$ tal que $P(X_n = i \mid X_0 = i) > 0$
- Supongamos ahora que encontramos un n_1 y un n_2 que lo cumplen, entonces también lo cumplirá el número $h \cdot n_1 + l \cdot n_2$ siendo h, l cualquier dos enteros positivos
- Buscamos entonces reconocer (o no) un patrón en la cantidad de pasos para volver al estado i

El período del estado i se define como,

$$k = \text{MCD} \{ n > 0 \mid P(X_n = i \mid X_0 = i) > 0 \}$$


(máximo
común
divisor)

Cadenas de Markov


Periodicidad de una cadena de Markov

$$k = \text{MCD} \{ n > 0 / P (X_n = i | X_0 = i) \}$$

- Si $k = 1$: el estado se dice **aperiódico**
- Si $k > 1$: el estado se dice **periódico**



Al estado 0 podemos regresar en **3 pasos** (0-1-2-0) y también en **5 pasos** (0-1-2-3-2-0). De esta manera $k = \text{MCD} \{ 3, 5 \} = 1$, y el estado es **aperiódico**



Cualquiera de los 4 estados es **periódico** de periodo 3

$$k = \text{MCD} \{ 3, 6, 9, \dots \} = 3$$

Cadenas de Markov

Periodicidad de una cadena de Markov

$$k = \text{MCD} \{ n > 0 \mid P(X_n = i \mid X_0 = i) \}$$

En una cadena irreducible todos los estados tienen el mismo periodo

- ☐ son todos **aperiódicos**
- ☐ son todos **periódicos**

Entonces para una cadena irreducible podemos hablar de **cadena** periódica o aperiódica

La periodicidad es clave para saber si una cadena converge a una **distribución estacionaria**

Cadenas de Markov

Distribución estacionaria

- Tenemos una cadena sobre un conjunto de estados $S = \{0, 1, 2, 3, \dots, N\}$
- Imaginemos que dejamos evolucionar la cadena por mucho tiempo
- Puede llegarse a una especie de “equilibrio”, en que la distribución de la cadena no cambia con el tiempo.
- La forma en que se reparten las probabilidades entre los estados ya se estabilizó

La distribución $\pi = (\pi_0, \pi_1, \pi_2, \dots, \pi_N)$ es estacionaria si,

$$\pi \cdot Q = \pi$$

Después de un paso la distribución sigue siendo la misma

Este tipo de situaciones se conocen como “punto fijo” del sistema

Cadenas de Markov

Distribución estacionaria: ejemplo

Sea $Q = \begin{pmatrix} 0,5 & 0,5 \\ 0,2 & 0,8 \end{pmatrix}$, busco $\pi = (\pi_1 \quad \pi_2)$ tal que

$$(\pi_1 \quad \pi_2) \begin{pmatrix} 0,5 & 0,5 \\ 0,2 & 0,8 \end{pmatrix} = (\pi_1 \quad \pi_2)$$

$$\Rightarrow \begin{cases} \pi_1 = 0,5 \pi_1 + 0,2 \pi_2 \\ \pi_2 = 0,5 \pi_1 + 0,8 \pi_2 \end{cases} \quad \text{y además } \pi_1 + \pi_2 = 1$$

$$\Rightarrow \begin{cases} \pi_1 \cong 0,286 \\ \pi_2 \cong 0,714 \end{cases}$$

Cadenas de Markov

Distribución estacionaria

Ergodicidad: Una cadena de Markov se dice **ergódica** si es irreducible, aperiódica y recurrente

- Teorema: Si una cadena de Markov es ergódica, entonces para todo $j \in S$ existe el límite

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = p_j$$

- ✓ Significa que las filas de la matriz Q^n tienden todas al mismo vector.
- ✓ Cuando este límite existe y además $\sum_{j \in S} p_j = 1$, entonces decimos que la cadena de Markov alcanza una distribución estacionaria.
- Teorema: Si además de ergódica es finita, entonces la existencia de la distribución estacionaria está garantizada.

Cadenas de Markov

Distribución estacionaria: volvamos al ejemplo del clima en Oz


	L	N	S
L	0.5	0.25	0.25
N	0.25	0.5	0.25
S	0.5	0.5	0

o específicamente $Q = \begin{pmatrix} 0.5 & 0.25 & 0.25 \\ 0.25 & 0.5 & 0.25 \\ 0.5 & 0.5 & 0 \end{pmatrix}$

Pueden leer la resolución matemática en el Ejemplo 9,7, página 176, del apunte nombrado antes: https://github.com/helcsnewsxd/models-and-simulation-subject/blob/main/clases/teorico/09_cadenas_de_markov.pdf

$$(p_0, p_1, p_2) = \left(\frac{2}{5}, \frac{2}{5}, \frac{1}{5} \right)$$

Yo prefiero hacerlo con python





FIN