



SIMULACIONES Y PROCESOS ESTOCÁSTICOS

2026

Teoría: Dr. Alejandro Mezio – mezioalejandro@uca.edu.ar

Práctica: Dr. Luis Herrera – lherrera@uca.edu.ar



PROCESOS ESTOCÁSTICOS Y NÚMEROS ALEATORIOS

Procesos estocásticos

Definición: Colección de variables aleatorias “similares” ordenadas en el tiempo, (y que están todas definidas en un mismo espacio muestral).

$X_1, X_2, X_3, \dots \rightarrow$ proceso estocástico de tiempo discreto

$\{X(t), t \geq 0\} \rightarrow$ proceso estocástico de tiempo continuo

Procesos de Poisson

Supongamos que “eventos” ocurren aleatoriamente en el tiempo, y llamemos $N(t)$ a la función que cuenta el número de eventos que ocurrieron desde el inicio hasta t , es decir en el intervalo $[0, t]$

$N(t)$ modela los procesos de “arribo”, como los A_i del modelo de colas.

En particular nos interesan los Procesos de Poisson

Procesos de Poisson

El proceso estocástico $\{N(t), t \geq 0\}$ se dice que es un **Proceso de Poisson** (homogéneo) de tasa o razón λ , si:

1. Los clientes arriban de a uno a la vez (no en grupo)
2. El número de eventos que ocurren en intervalos de tiempo disjuntos son independientes. (*suposición del incremento independiente*)

Nro de arribos en $[0, t]$ es $N(t)$

Nro de arribos en $[t, t + s]$ es $N(t + s) - N(t)$

$N(t + s) - N(t)$ es independiente de $N(t)$, e incluso es independiente de todos los $N(u)$, con $0 \leq u \leq t$

3. La distribución de $N(t + s) - N(t)$ para cualquier t, s es independiente de t . (*suposición de incremento estacionario*)

La distribución del número de eventos en un intervalo $[t, t + s]$ sólo depende de la longitud del intervalo, es decir, de s .

La distribución de $N(t + s) - N(t)$ es la misma para cualquier t . (λ es constante)

Procesos de Poisson

Teorema: Si $\{N(t), t \geq 0\}$ es un Proceso de Poisson, entonces el número de arribos en cualquier intervalo de tiempo de longitud s es una variable aleatoria de Poisson (distribución discreta!) con tasa $\lambda \cdot s$, es decir:

$$P(N(t + s) - N(t) = k) = \frac{e^{-\lambda s} (\lambda s)^k}{k!}$$

(No olvidemos que s mide tiempo, el tiempo que dura el intervalo $[t, t + s]$)

Es la variable aleatoria X de cuando vimos la distribución discreta de Poisson, sólo que ahora cambiamos $\lambda \rightarrow \lambda s$

$$\text{Poisson} \rightarrow P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

$$E[N(s)] = \lambda s \longrightarrow E[N(1)] = \lambda$$

λ es el número de arribos esperado por unidad de tiempo (cuántos arribos ocurren en 1 unidad de tiempo)

Procesos de Poisson

Otro Teorema: Si $\{N(t), t \geq 0\}$ es un Proceso de Poisson con tasa λ , entonces los correspondientes tiempos e interarribos $A_1, A_2, \dots$ son variables aleatorias IID (Independientes e Idénticamente Distribuidas) con distribución exponencial y tasa media $1/\lambda$.


RESUMIENDO: Llegada de clientes a un modelo de colas,

Cantidad de clientes que llegan en
intervalo de tiempo t



Variable aleatoria discreta con
distribución de Poisson (media λt)

Tiempo que ocurre entre la llegada
de un cliente y el siguiente



Variable aleatoria continua de
distribución exponencial (media $\frac{1}{\lambda}$)

Procesos de Poisson

Posibles problemas/mejoras:

~~1. Los clientes arriban de a uno a la vez (no en grupo)~~

No se mantendría si los clientes llegaron en grupos

~~2. El número de eventos que ocurren en intervalos de tiempo disjuntos son independientes. (suposición del incremento independiente)~~

Esta propiedad podría violarse si por ejemplo llegan muchos clientes en el intervalo $[0, t]$, y esto provoca que algunos clientes que llegan durante el intervalo $[t, t + s]$ desistan y se retiren sin obtener el servicio (la cola es larga, mucha congestión)

~~3. La distribución de $N(t + s) - N(t)$ para cualquier t, s es independiente de t . (suposición de incremento estacionario)~~

Es más común que no se mantenga, ya que asume que la razón de arribo se mantiene constante durante toda la simulación (sirve para simular períodos cortos).

En muchos casos reales tendremos que utilizar un $\lambda(t) \rightarrow$ Poisson no-homogéneo

Generación de Número Aleatorios

No existe una definición general sobre número aleatorio, depende mucho del contexto.

Cualquier número o secuencia de números puede parecer aleatoria para algún observador, pero no para aquel otro que conoce la ley que los genera.

Podría decirse que “un número aleatorio se define como un número seleccionado en un proceso aleatorio desde un conjunto finito de números”

¿Qué significa entonces “aleatoriedad” al elegir ese número?

Generación de Número Aleatorios

Métodos previos a las computadoras:

- Físicos: dados, bolilleros, moneda, etc
- Tablas con muchos dígitos aleatorios

¿Qué inconvenientes tienen al usarse en simulaciones?

- No puede repetirse la misma secuencia
- No hay velocidad computacional

Con las computadoras surgen algoritmos de generación de secuencias de números aleatorios

Generación de Número Aleatorios

En simulación se utiliza la generación de números pseudoaleatorios con distribución uniforme en el intervalo $[0,1]$

Los usaremos:

- De forma directa, ya que necesitamos generar una distribución uniforme en $[0,1]$.
- Para generar muestras de otras variables aleatorias con otras distribuciones, tanto discretas como continuas.

Generación de Número Aleatorios

Aleatorio: Distribución Uniforme

Un generador de números aleatorios RAZONABLE debería cumplir lo siguiente:

1. Repetibilidad *(por eso pseudoaleatorios)*

Al repetir los parámetros del generador se repite la secuencia (da confiabilidad)

2. Portabilidad

No debe depender del lenguaje ni computadora utilizada (misma definición, mismas sucesión de números)

3. Velocidad computacional

La velocidad en la generación de números está ligada con la precisión. Más velocidad, generación de secuencias más largas, generación de resultados más confiables o precisos.

Generación de Número Aleatorios

Aleatorio: Distribución Uniforme

Un generador de números aleatorios RAZONABLE debería cumplir las siguientes propiedades:

1. Repetibilidad

Al repetir los parámetros del generador se repite la secuencia (da confiabilidad)

2. Portabilidad

No debe depender del lenguaje ni computadora utilizada (misma definición, mismas sucesión de números)

3. Velocidad computacional

La velocidad en la generación de números está ligada con la precisión. Más velocidad, generación de secuencias más largas, generación de resultados más confiables o precisos.

Generación de Número Aleatorios

Principios generales:

1. La secuencia generada debe ser intuitivamente aleatoria
2. La aleatoriedad debe ser establecida teóricamente o, por lo menos, cumplir ciertos tests de aleatoriedad
3. Debe conocerse algo sobre las propiedades teóricas del generador (para garantizar la repetibilidad)

Generación de Número Aleatorios

2. La aleatoriedad debe ... cumplir ciertos tests de aleatoriedad

El grupo de variables aleatorias $(U_1, U_2, \dots, U_N)$ se dice que es una muestra de tamaño N de una variable aleatoria discreta uniforme en $[0,1]$ si cumple:

- La secuencia de números $(U_1, U_2, \dots, U_N)$ debe estar uniformemente distribuida en $[0,1]$
- Los pares de números (U_i, U_{i+1}) tienen que estar uniformemente distribuidos en el cuadrado $[0,1] \times [0,1]$.

Similarmente para las ternas (U_i, U_{i+1}, U_{i+2}) en el cubo $[0,1] \times [0,1] \times [0,1]$

(más adelante veremos algunos tests estadísticos mas formales)

Generación de Número Aleatorios

Las desventajas o problemas más comunes en un generador de números aleatorios:

- Los números no están uniformemente distribuidos
- Los números generados están discretizados
- Media o Varianza incorrectas
- Presentan variaciones cíclicas

Generación de Número Aleatorios

Ejemplo, método “mid square” de von Neumann

1. X_0 : número de 4 dígitos

$$X_0 = 1234$$

2. Calculamos X_0^2 y lo escribimos con 8 dígitos

$$X_0^2 = 01\textcolor{red}{5227}56$$

3. X_1 lo tomamos como los 4 dígitos centrales

$$X_1 = 5227$$

4. Repetir 2 y 3 con este nuevo número

$$X_1^2 = 27\textcolor{red}{3215}29$$

$$X_2 = 3215$$

...

ver notebook

Generación de Número Aleatorios

Ejemplo, método “mid square” de von Neumann

Se obtienen algunas secuencias bien aleatorias y que se repiten recién después de un número bien grande. Sin embargo, éste es un mal generador, ya que no se conocen bien sus propiedades.

El resultado depende fuertemente de la semilla X_0 .

Probar con 4010, 2100, 3792

Generación de Número Aleatorios

Generador Congruencial Lineal (LCG)

Para un número entero M grande, este generador produce una secuencia de números enteros positivos siempre menores a M .

$y_1, y_2, y_3, \dots, y_N$ donde cada número $y_j \in \{0, 1, 2, 3, \dots, M - 2, M - 1\}$

y de esta muestra obtenemos la sucesión de números en $[0, 1)$

$$u_1 = \frac{y_1}{M}, \quad u_2 = \frac{y_2}{M}, \quad \dots, \quad u_N = \frac{y_N}{M}$$

Generación de Número Aleatorios

Generador Congruencial Lineal (LCG)

La idea entonces es generar secuencias de números $y_i = f(y_{i-1}) \mod M$

Generador congruencial lineal: $y_n = (ay_{n-1} + c) \mod M$

- a : multiplicador
- c : incremento
- M : módulo
- y_0 : semilla

ver notebook

Generación de Número Aleatorios

Generador Congruencial Lineal (LCG)

- La secuencia tiene a lo sumo M valores diferentes
- Si un número se repite, entonces la secuencia que sigue al mismo se repite

Llamaremos período al número K en que la secuencia comienza a repetirse: $y_n = y_{n+K}$

- ¿Cómo escoger a, c, M, y_0 para tener el mayor período K posible?
- También es importante escogerlos de tal manera que la secuencia sea lo mas aleatoria posible

Generación de Número Aleatorios


Generador Congruencial Lineal (LCG)

- De manera general, eligiendo un valor grande de $M (> 10^9)$ podemos reducir simultáneamente el fenómeno de periodicidad y (quizás) la aleatoriedad
- Además, hay criterios matemáticos para elegir los 3 parámetros a, c, M para (posiblemente) maximizar el período
- Lewis-Learmonth: $M = 2^{31} - 1, a = 75, c = 0$
- RANDU: $M = 2^{31}, a = 2^{16} + 3, c = 0$ (no tan bueno como deseamos)

ver notebook


Generación de Número Aleatorios

Generador Congruencial Lineal (LCG)




Generación de Número Aleatorios

Generador Congruencial Lineal (LCG)




Generación de Número Aleatorios

Generador Congruencial Lineal (LCG)



(a) The MLCG with $m = 2^{31} - 1$ and $a = 16807$.



(b) The MLCG with $m = 2147483399$ and $a = 40692$.

Generación de Número Aleatorios

Generador de Fibonacci Resagado

La idea es generar el nuevo número utilizando los dos anteriores (y no sólo uno). Esto nos permitiría un período más largo

- Caso más sencillo: $y_{n+1} = (y_n + y_{n-1}) \mod M$ (no satisfactorio)
- Para algún k : $y_{n+1} = (y_n + y_{n-k}) \mod M$ (mejor, pero tampoco!)
- Mitchell & Moore (1958): $y_{n+1} = (y_{n-24} + y_{n-55}) \mod M$ (para $n \geq 55$)

M es par y los 54 anteriores son nros enteros arbitrarios (no todos pares)

ver notebook

Muy sensible a las condiciones iniciales

Generación de Número Aleatorios

Librería random

- `random.random()`
- `random.seed()`
- `random.uniform()`
- `random.randint()`
- `random.randrange()`
- `random.choice()`
- `random.sample()`

ver notebook

Testeos para números aleatorios

(Sheldon Ross, capítulo 11)

- Llamados testeos de “bondad del ajuste”
- Partimos el rango de valores posibles en un número finito de regiones, contamos los números que caen dentro de cada región, y comparamos con la cantidad teórica esperada.

Testeos para números aleatorios

Testeo chi-cuadrado

- Tenemos n variables aleatorias independientes $Y_1, Y_2, Y_3, \dots, Y_n$
(esta sería la secuencia de números aleatorios de nuestro generador)
- Cada una de estas variables toma alguno de los k valores $1, 2, 3, \dots, k$.
(es decir, las variables aleatorias pertenecen a una distribución discreta de k valores)
- Sea p_i la función de masa de probabilidad del elemento $i = 1, 2, \dots, k$.
(para la distribución uniforme es $p_i = 1/k$)
- Queremos testear nuestra hipótesis de que p_i es la distribución de masa de probabilidad de las variables aleatorias.

Testeos para números aleatorios

Testeo chi-cuadrado

- Hipótesis nula:

$$H_0: P(Y = i) = p_i, \quad i = 1, 2, \dots, k$$

- Llamamos N_i al número de valores Y_j que son iguales a i (también llamada frecuencia observada)
- Analogamente, el número teórico esperado según la distribución será $n \cdot p_i$
- El valor chi-cuadrado se calcula:

$$\chi^2 = \sum_{i=1}^k \frac{(N_i - n \cdot p_i)^2}{n \cdot p_i}$$

Testeos para números aleatorios

Testeo chi-cuadrado

- En nuestro caso de la distribución uniforme $n \cdot p_i = n/k$, entonces:

$$\chi^2 = \frac{k}{n} \sum_{i=1}^k \left(N_i - n/k \right)^2$$


- La idea es que $(N_i - n \cdot p_i)^2$ da una medida de cuán cerca es p_i a la probabilidad que obtengo de la secuencia de números. Un valor muy grande da cuenta de que la hipótesis nula no es correcta.
- Entonces rechazaremos la hipótesis nula si χ^2 es muy grande
- ¿Cuán grande?

Testeos para números aleatorios

Testeo chi-cuadrado

- Para n grande, χ^2 se aproxima a una distribución chi-cuadrado con $k - 1$ grados de libertad
- Por lo tanto, rechazaremos la hipótesis nula a un nivel α si $\chi^2 > \chi_{k-1, 1-\alpha}^2$

Ver ejemplo en notebook



Testeos para números aleatorios

Testeo chi-cuadrado

- Puede usarse también para distribuciones continuas
- Dividimos el rango entero de la distribución teórica en k intervalos adyacentes: $[a_0, a_1), [a_1, a_2), \dots, [a_{k-1}, a_k)$
- N_i : número de Y_j que caen en el i -ésimo intervalo (frecuencia observada)
- Y la probabilidad teórica para cada intervalo es:

$$p_i = \int_{a_{i-1}}^{a_i} f(x) dx$$

- Luego calculamos χ^2 igual que antes y evaluamos de la misma manera

Testeos para números aleatorios

Testeo Kolmogorov-Smirnov

- El test chi-cuadrado puede entenderse como una comparación entre el histograma de los datos (la frecuencia empírica N_i) con la función de masa de probabilidad (la frecuencia teórica $n \cdot p_i$).
(en caso continuo p_i es la integral de la función densidad de probabilidad)
- El test de Kolmogorov-Smirnov, por otro lado, compara las funciones de distribución acumuladas (empírica vs teórica)

Testeos para números aleatorios

Testeo Kolmogorov-Smirnov

- Nuevamente, tenemos n variables aleatorias independientes $Y_1, Y_2, Y_3, \dots, Y_n$
- Pero esta vez queremos testear si éstas provienen de una distribución continua.
- Entonces la hipótesis nula H_0 será que las variables aleatorias independientes Y_j provienen de una función de distribución acumulada F
- Recordemos que: $\int_a^b f(x) dx = F(b) - F(a)$
- Necesitamos ahora construirnos la función de distribución acumulada EMPÍRICA, la que resulta de la secuencia $Y_1, Y_2, Y_3, \dots, Y_n$:

$$F_e(x) = \frac{\#i: Y_i \leq x}{n}$$


Testeos para números aleatorios

Testeo Kolmogorov-Smirnov

- Así, $F_e(x)$ es la proporción de los valores observados que son menores o iguales a x .
- Entonces si la hipótesis nula es correcta, F_e y F deberían ser similares
- Estadística del test Kolmogorov-Smirnov:

$$D = \max_x [|F_e(x) - F(x)|]$$

Es simplemente la mayor distancia (vertical) entre F_e y F



Testeos para números aleatorios

Testeo Kolmogorov-Smirnov

- Un valor grande de D habla de una discrepancia entre F_e y F
- La hipótesis nula será rechazada si $D > d_{n,1-\alpha}$
(α es el nivel de especificidad del test)
- El valor crítico $d_{n,1-\alpha}$ depende de si conocemos o no todos los parámetros de la distribución teórica, y cuál distribución es. Son valores numéricos tabulados

Ver notebook

Generación de Distribuciones

Método de la Transformada Inversa

- Supongamos queremos generar una variable aleatoria X que es continua y su función de distribución acumulada es F
- F es continua y estrictamente creciente cuando $0 < F(x) < 1$
- Entonces podemos calcular F^{-1} la función inversa de F
- De esta manera, un algoritmo sencillo para generar X es:
 1. Generar la variable aleatoria con distribución uniforme $U \sim U(0,1)$
 2. Evaluar $X = F^{-1}(U)$

Generación de Distribuciones

Método de la Transformada Inversa

- Como $0 \leq U \leq 1$ entonces $F^{-1}(U)$ estará siempre bien definida
- Gráficamente:




FIGURE 8.1

Inverse-transform method for continuous random variables.

Generación de Distribuciones

Método de la Transformada Inversa

- Ejemplo: Sea X de una distribución exponencial con media $\beta = 1/\lambda$
- Entonces la función de distribución acumulada:

$$F(x) = \begin{cases} 1 - e^{-x/\beta}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

- Y su función inversa será:


$$F^{-1}(u) = -\beta \ln(1 - u)$$

1. Generamos $U \sim U(0,1)$
2. Evaluar $X = -\beta \ln(1 - U)$

Generación de Distribuciones

Método de la Transformada Inversa

- Interpretación gráfica:



Generación de Distribuciones

Método de la Transformada Inversa

- Puede utilizarse también para distribuciones discretas, notando que:

$$F(x) = P(X \leq x) = \sum_{x_i \leq x} p(x_i)$$

donde $p(x_i) = P(X = x_i)$ es la función de masa de probabilidad




FIGURE 8.4

Inverse-transform method for discrete random variables.

1. Generamos $U \sim U(0,1)$

2. Determinamos el menor entero positivo I tal que $U \leq F(x_I)$, y entonces $X = x_I$

Generación de Distribuciones

Método de Aceptación-Rechazo

- A veces no es posible calcular F^{-1}
- Podemos utilizar este método cuando disponemos de una ley de distribución definida en un intervalo finito $[a, b]$, es decir, conocemos la función densidad de probabilidad $f(x)$ de la variable aleatoria X que queremos generar.
- Llamando c al máximo valor que alcanza $f(x)$ en $[a, b]$, podemos decir que la imagen de f es $[0, c]$.
- Pensamos entonces en un rectángulo de lados $[a, b] \times [0, c]$, como vemos en la próxima figura


Generación de Distribuciones

Método de Aceptación-Rechazo

- Lo que hacemos es generar puntos aleatorios dentro del rectángulo
- Generamos dos secuencias aleatorias uniformes en $[0,1]$: U_1 y U_2
- y con estas derivamos otras dos secuencias aleatorias uniformes:

$$\begin{cases} X = a + (b - a) \cdot U_1 \\ Y = c \cdot U_2 \end{cases}$$

- Así, a cada par (U_1, U_2) le corresponde el par (X, Y) dentro del rectángulo
- Si (X, Y) cae debajo de $f(x)$, es aceptado. Si no, es rechazado



Generación de Distribuciones

Método de Aceptación-Rechazo

- Los puntos X aceptados forman una secuencia de números aleatorios que sigue la distribución $f(x)$




FIGURE 8.10

Sample of 50 X 's (on horizontal axis) and the required $(Y, Ut(Y))$ pairs, acceptance-rejection method for beta(4, 3) distribution.

Método de Aceptación-Rechazo

Estimando integrales definidas

- Los puntos X aceptados forman una secuencia de números aleatorios que sigue la distribución $f(x)$
- Y la proporción de puntos aceptados es igual a la proporción del área bajo $f(x)$ respecto del área del rectángulo (idea Monte Carlo).




FIGURE 8.10

Sample of 50 X 's (on horizontal axis) and the required $(Y, U_t(Y))$ pairs, acceptance-rejection method for beta(4, 3) distribution.



FIN